

Datorlaboration 7

Josef Wilzén och Måns Magnusson

1 mars 2019

Instruktioner

- Denna laboration ska göras i grupper om **två och två**. Det är viktigt för gruppindelningen att inte ändra grupper.
 - En av ska vara **navigatör** och den andra **programmerar**. Navigatörens ansvar är att ha ett helhetsperspektiv över koden. Byt position var 20:e minut. Båda ska vara engagerade i koden.
 - Det är tillåtet att diskutera med andra grupper, men att plagiera eller skriva kod åt varandra är **inte tillåtet**. Det är alltså **inte** tillåtet att titta på andra gruppars lösningar på inlämningsuppgifterna.
 - Använd inte å, ä eller ö i variabel- eller funktionsnamn.
 - Utgå från laborationsfilen, som går att ladda ned **här**, när du gör inlämningsuppgifterna.
 - Spara denna som `labb[no]_grupp[no].R`, t.ex. `labb5_grupp01.R` om det är laboration 5 och ni tillhör grupp 1. Ta inte med hakparenteser eller stora bokstäver i filnamnet.
Obs! Denna fil ska laddas upp på LISAM och ska **inte** innehålla något annat än de aktuella funktionerna, namn-, ID- och grupp-variabler och ev. kommentarer. Alltså **inga** andra variabler, funktionsanrop för att testa inlämningsuppgifterna eller anrop till markmyassignment-funktioner.
 - Om ni ska lämna i kompletteringar på del 2, döp då dessa till `labb5_grupp01._komp1.R` om det är första kompletteringstillfället. Se kurshemsidan för mer information om kompletteringar.
 - Laborationen består av två delar:
 - Datorlaborationen
 - Inlämningsuppgifter
 - I laborationen finns det extrauppgifter markerade med *. Dessa kan hoppas över.
 - Deadline för laboration framgår på **LISAM**
 - **Tips!** Använd ”fuskklapparna” som finns **här**. Dessa kommer ni också få ha med på tentan.
-

Innehåll

I Datorlaboration	3
1 Introduktion till ggplot2	4
1.1 Grunden i ggplot2	4
1.1.1 Skapa en ggplot (linje eller scatter)	5
1.1.2 Enklare modifikationer av ett ggplot-objekt	6
1.1.3 Barplot, histogram och boxplot	6
1.1.4 Histogram	7
1.1.5 Boxplot	8
1.2 Grafiska teman/profiler	9
2 Enklare statistisk analys	12
2.1 Enklare statistiska metoder mm	12
2.1.1 Kombinatorik	12
2.1.2 Korstabulering och χ^2 -tester	12
2.1.3 t-test	13
2.1.4 Sambandsmått	13
2.1.5 Beskrivande statistik	14
2.2 * Extraproblem	14
3 Housing data	15
4 Frivillig fördjupning: Introduktion till linjär regression	17
4.1 Anpassa en regressionsmodell	17
4.2 Analysera resultatet från en linjär regression	19
4.2.1 Använda parametrar och resultat för vidare analys	19
4.3 Tester och diagnostik	20
4.3.1 Anscombes data	21
II Inlämningsuppgifter	22
5 Inlämningsuppgifter	24
5.1 my_grouped_test()	24
5.2 Miniprojektet del II	25

Del I

Datorlaboration

Kapitel 1

Introduktion till ggplot2

Paketet `ggplot2` skiljer sig från den grundläggande grafikfunktionaliteten som finns implementerat i R. Paketet bygger på vad som brukar kallas “The grammar of graphics” (därav `gg` i `ggplot2`) och är ett försök till ett formellt språk för att uttrycka hur en visualisering ska se ut. Mer teori bakom denna grammatik går att finna i [3, 2, 1] och är grunden bakom exempelvis SPSS grafiksystem. Genom att ha en grundläggande förståelse för denna grammatik kan vi enkelt och snabbt skapa mycket komplicerade visualiseringar.

I R:s basgrafiksystem kunde man se grafikfunktionaliteten lite som ett papper vi ritar på. Vi ritar initialt upp vår graf och kan sedan lägga till/rita ”ovanpå” det befintliga pappret. `ggplot` är annorlunda. Med `ggplot` skapar vi ett grafikobjekt och vi kan lägga till bit för bit av grafen för att när vi sedan är klar med vår graf visualisera den. Det gör det enklare att bygga upp komplicerade grafer utan att behöva använda särskilt mycket kod.

[Här](#) och [här](#) finns bra kataloger över de flesta graferna i `ggplot2`.

1.1 Grunden i ggplot2

Till skillnad från basgrafen utgår `ggplot` **alltid** från en `data.frame`. Baserat på denna `data.frame` skapas sedan grafen med två huvudsakliga komponenter:

- `aes` (aesthetic) som handlar om utseendet på grafen, färger, former m.m.
- `geom` (geometrics) som beskriver vilken typ av graf vi vill ha (bar, line, points)

Vi lägger sedan till dessa komponenter till vår graf och `data.frame`.

När det gäller de olika geometriska argumenten, d.v.s. de olika typer av grafer som går att skapa, finns det ett mycket stor antal vi kan använda oss av. Några exempel är:

geom	Beskrivning
<code>geom_point</code>	Scatterplot
<code>geom_line</code>	Line graph
<code>geom_bar</code>	Barplot
<code>geom_boxplot</code>	Boxplot
<code>geom_histogram</code>	Histogram

Exakt hur dessa geometriska figurer ska se ut styrs sedan med `aes`. Nedan finns några exempel:

aes	Beskrivning
<code>x</code>	x-axel
<code>y</code>	y-axel
<code>size</code>	storlek
<code>col</code>	färg
<code>shape</code>	form

De enskilda geometriska figurerna kan i sin tur ha ett antal olika aesthetics. Nedan finns lite exempel.

geom	Specifika aesthetics
geom_points	point shape, point size
geom_line	linetype, line size
geom_bar	y min, y max, fill color, outline color

Med dessa verktyg har vi en grund för att bygga upp ett mycket stort antal visualiseringar.

1.1.1 Skapa en ggplot (linje eller scatter)


- Vi börjar med att läsa in the datamaterialet `Nile`.

```
library(ggplot2)

data(Nile)
Nile <- data.frame(level=as.vector(Nile))
Nile$years <- 1871:1970
```

- För att skapa en `ggplot` börjar vi med att skapa grunden för plotten med funktionen `ggplot()`. Nedan är ett exempel på att skapa en `ggplot` med `Nile`, sedan lägger vi till att `x` ska utgöras av variabeln `years` och `level`. Sedan lägger vi till att plotten ska utgöras av punkter. Vi sparar grafen som variabeln `p`. För att skapa den tittar vi bara på `p`:

```
p <- ggplot(data=Nile) + aes(x=years, y=level) + geom_point()
p
```



- Vill vi ändra till en linjegraf (vilket känns bättre) här byter vi bara ut geometrin:

```
p <- ggplot(data=Nile) + aes(x=years, y=level) + geom_line()
```

- Vill vi lägga till både punkter och linjer i samma graf kan vi bara ta `p` och lägga till punkter. Här blir det tydligt hur vi i `ggplot` lägger till lager på lager och sedan producerar en visualisering:

```
p <- p + geom_point()
```

5. På samma sätt kan vi också lägga till rubriker och axelettiketter:

```
p <- p + xlab("Years") + ylab("Water level") + ggtitle("Nile series")
```

1.1.2 Enklare modifikationer av ett ggplot-objekt

1. Vill vi ändra färg och form på olika delar i en graf behöver vi ange exakt var dessa förändringar ska ske.

```
p <- ggplot(data=Nile) + aes(x=years, y=level) + geom_line(color="red", size=3) +  
geom_point(color="blue", size=4)
```

2. Om vi nu vill förtydliga vissa delar av grafen med olika färger eller använder vi `aes` i den del av grafen vi vill ändra. Först ska vi skapa en ny faktorvariabel vi vill visualisera.

```
Nile$period <- "- 1900"  
Nile$period[Nile$years >= 1900] <- "1900 - 1945"  
Nile$period[Nile$years > 1945] <- "1945 + "  
Nile$period <- as.factor(Nile$period)
```

3. Vill vi nu exempelvis lyfta in visualiseringen i linjerna måste vi lägga `aes` där.

```
p <- ggplot(data=Nile) + aes(x=years, y=level) + geom_line(aes(color=period)) + geom_point()
```

4. Vill vi istället modifiera punkterna lägger vi till det i `geom_point()`.

```
p <- ggplot(data=Nile) + aes(x=years, y=level) + geom_line() + geom_point(aes(color=period))
```

5. Vill vi lägga det i hela grafen kan vi lägga till färgen i den huvudsakliga styrningen av aesthetics i grafen.

```
p <- ggplot(data=Nile) + aes(x=years, y=level, color=period) + geom_line() + geom_point()
```

6. Baserat på graferna ovan prova att göra följande förändringar:

- Ändra typ av linje i grafen [**Tips!** `linetype`]
- Ändra typ av punkter i grafen [**Tips!** `shape`]
- Gör punkterna transparaenta [**Tips!** `alpha`]

1.1.3 Barplot, histogram och boxplot

För att prova dessa diagram använder vi oss av datamaterialet mtcars. Vi börjar med att läsa in datamaterialet mtcars. För att få mer information om detta datamaterial, använd `?mtcars`. Vi gör också om:

```

data(mtcars)
mtcars$cyl <- as.factor(mtcars$cyl)
mtcars$gear <- as.factor(mtcars$gear)

```

Till skillnad från basgrafen använder vi inte olika funktioner för olika plottar utan vi använder bara olika `geoms`.

- Vill vi exempelvis skapa ett stapeldiagram anger vi bara en axel och ett annat geom, men i övrigt är det inge större skillnad mot en linjegraf:

```
p <- ggplot(data=mtcars) + aes(x=cyl) + geom_bar()
```

- Vi kan också enkelt lägga till funktionen `coord_flip()` för att skapa ett liggande stapeldiagram istället för ett stående.

```
p + coord_flip()
```

- Skillnaden ligger i att det finns lite andra aesthetics för stapeldiagram än för övriga diagram som `fill`.

```
p <- ggplot(data=mtcars) + aes(x=cyl) + geom_bar(fill="darkblue", colour="red")
```

- För att skapa stapeldiagram med flera grupper behöver vi dels lägga till en till variabel som indikerar att vi vill ha ex. olika färger för olika grupper samt ange hur dessa diagram ska se ut. Pröva exemplen nedan:

```

p <- ggplot(data=mtcars) + aes(x=cyl, fill=gear) + geom_bar(position="stack")
p <- ggplot(data=mtcars) + aes(x=cyl, fill=gear) + geom_bar(position="dodge")
p + scale_fill_discrete(name="Testa\nDetta")
p + scale_fill_manual(values=c("black", "blue", "red"))

```


1.1.4 Histogram

- Den egentliga skillnaden mellan ett stapeldiagram och ett histogram är bara huruvida variabeln är kontinuerlig eller inte. Detta gör att för att skapa ett histogram gör vi på exakt samma sätt, men vi använder oss av en kontinuerlig variabel:

```

p <- ggplot(data=mtcars) + aes(x=mpg) + geom_bar(fill="darkblue", colour="red")
p

```



2. Sättet ovan är ett sätt att skapa ett histogram. Vi kan också använda den specialgjorda geometriska funktionen `geom_histogram()` om vi vill kunna hantera histogram enklare.


```
p <- ggplot(data=mtcars) + aes(x=mpg)
p <- p + geom_histogram(fill="darkblue", colour="red", binwidth=10)
p
```

1.1.5 Boxplot

1. Boxplottar är egentligen en kombination av kontinuerliga variabler. Precis som tidigare inleder vi skapa en `ggplot` med ett datamaterial och definierar vilka variabler vi vill använda.

```
p <- ggplot(data=mtcars) + aes(x=cyl, y=mpg) + geom_boxplot()
p

Warning: Continuous x aesthetic -- did you forget aes(group=...)?
```



2. Vill vi sedan göra förändringar kan vi lägga till det till och från.

```
p + coord_flip() + xlab("X") + ggtitle("Hejsan")
```


1.2 Grafiska teman/profiler

En av de stora fördelarna med att `ggplot` skiljer ut själva plotten från utseendet är att det är enkelt att skapa strukturer för olika delar av en graf som vi vill använda flera gånger. En av de bästa exemplen på detta är teman i `ggplot`. Ett tema är en uppsättning med inställningar för en grafisk profil som vi vill använda i `ggplot2`.


Den stora fördelen är att har vi väl skapat ett tema (vilket kan ta lite tid) kan temat läggas till mycket enkelt till samtliga grafer. Detta underlättar kopplingen mellan exempelvis grafiska profiler och de grafer som produceras, vilket gör att `ggplot2` är mycket populärt i företag och organisationer. Ett exempel på rapport som använder `ggplot2` genomgående är Pensionsmyndighetens [Orange rapport].

1. Med `ggplot2` kommer en del teman förinstallerade och precis som allt annat i R är det enkelt att bara lägga till den grafiska profilen efter att vi skapat en graf.

```
p <- ggplot(data=Nile) + aes(x=years, y=level) + geom_line() + geom_point()
p
```



```
p <- p + theme_bw()
p
```




2. Pröva på liknande sätt följande teman: `theme_grey()`, `theme_classic()`.
3. Ett tema i `ggplot2` är bara en funktion, så det är enkelt att titta på hur temat ser ut och sedan utgå från ett befintligt tema för att anpassa det till det utseende vi själva vill ha. Sedan kan detta tema enkelt spridas till alla som arbetar med visualisering med `ggplot`.


```
theme_bw
```

4. Att ändra den grafiska profilen innebär då bara att ändra denna temafunktion (även om det kan innebära en del jobb).
5. Det finns också ett separat R-paket med ett antal vanliga teman kallat `ggthemes`. De olika teman som är installerade i `ggthemes` framgår [[här](#)].
6. Med dessa går det enkelt att skapa olika färgsättningar för samma graf. I `ggthemes`-paketet finns också färgpaletter som passar bra för personer som är färgblinda.


```
library(ggthemes)
p + theme_excel()
```



```
p + theme_economist()
```



```
p + theme_tufte()
```



Kapitel 2

Enklare statistisk analys

2.1 Enklare statistiska metoder mm

2.1.1 Kombinatorik

1. Det finns inbyggda funktioner i R för kombinatorik. Testa att köra `?Special`. Leta reda på `factorial()` och `choose()` och läs om dem.
2. Faktulet: Beräkna nu $3!$, $6!$, och $12!$ med funktionen `factorial()`.
3. Binomialkoefficienter: Räkna nu ut följande $\binom{10}{2}$, $\binom{4}{2}$ och $\binom{20}{5}$ med funktionen `choose()`.
4. Skapa nu en egen funktion för binomialkoefficienter utan att använda `choose()`. Tips `?factorial()`
5. Nu ska ni implementera en funktion som ska beräkna tätetsfunktionen för för binomalfördelningen. Titta i `?dbinom` och se hur tätheten beräknas. Ni kan sedan använda `dbinom()` för att se om funktionen räknar rätt. Testa med några olika värden för `n` och `p`.

2.1.2 Korstabulering och χ^2 -tester

1. Vi börjar med att läsa in det interna datasetet `iris` med `data(iris)` i R. Vi ska nu använda detta dataset för att pröva att analysera data i R.

```
data(iris)
```

2. Som ett första steg vill vi pröva att producera korstabeller. I `iris` finns bara en kategorisk variabel, därför klassindlear vi två kontinuerliga variabler på följande sätt:

```
iris$Petal.Length.Cat <- cut(iris$Petal.Length, breaks=3)
iris$Sepal.Length.Cat <- cut(iris$Sepal.Length, breaks=3)
```

3. Vi börjar med att skapa en korstabell på följande sätt:

```
table(iris$Petal.Length.Cat, iris$Species)
```

4. När vi vill använda flera kategoriska variabler är `ftable()` lämpligt:

```
ftable(iris$Petal.Length.Cat, iris$Sepal.Length.Cat, iris$Species)
```

5. För att göra ett χ^2 -test använder vi funktionen `chisq.test()`. Funktionen behöver en tabell att testa, så vi skapar och sparar tabellen ovan och testar den sedan..

```
tab <- table(iris$Petal.Length.Cat, iris$Species)
chisq.test(tab)
```

6. Om vi tittar på tabellen ovan är det många värden som är 0 (d.v.s. mindre än 5). Då behöver vi korrigera vårt test med **Yates korrektion**. Detta kan vi göra i R genom att lägga till argumentet `correct=TRUE`.

```
chisq.test(tab, correct=TRUE)
```

7. Ett annat sätt är att använda **Fishers exakta test** istället. Det görs på följande sätt:

```
fisher.test(tab)
```

2.1.3 t-test

1. Vill vi jämföra två grupper avseende en kontinuerlig variabel använder vi funktionen `t.test()`. Inledningvis kan vi testa om `Sepal.Length` för `iris versicolor` är mindre 6. Vi börjar med att plocka ut elementen för de olika arterna:

```
versLength <- iris$Sepal.Length[iris$Species=="versicolor"]
t.test(x=versLength, alternative="greater", mu=6)
```

2. Om vi nu vill testa om skillnaden mellan två blomsterarter är olika anger vi två vektorer, en för varje art:

```
virginLength <- iris$Sepal.Length[iris$Species=="virginica"]
t.test(x=versLength, y=virginLength)
```

2.1.4 Sambandsmått

För att studera samband mellan två eller flera kontinuerliga variabler studerar vi ofta korrelation och kovarians.

1. För att beräkna kovarians och korrelation används `cov()` och `cor()`.

```
cor(iris$Petal.Length, iris$Petal.Width)
cov(iris$Petal.Length, iris$Petal.Width)
```

2. Vi kan också enkelt skapa kovarians- och korrelationsmatriser på samma sätt:

```
cor(iris[,1:4])
cov(iris[,1:4])
```

3. Vill vi göra ett enkelt hypotestest för korrelationen använder vi `cor.test()`:

```
cor.test(iris$Petal.Length, iris$Petal.Width)
```

2.1.5 Beskrivande statistik

1. Hitta det hösta och minsta värdet i `iris` (för alla variabler). Ta reda på vilken rad dessa värden finns på med relationsoperatorn `==` och `which.max()`.
 - (a) Beräkna medelvärden för alla kolumnerna med `colMeans()`.
 - (b) Beräkna nu kvartiler för `Petal.Width` med funktionen `quantiles()`. Beräkna den 1 och 99 procentiga percentilern? [Tips! `?quantile`]
 - (c) Beräkna nu kvartiler för samtliga variabler.
 - (d) Testa nu att använda funktionen `summary()` på `Petal.Width` först och sedan på hela datasettet. Vad får du för resultat?
2. Skapa en logisk vektor som anger om en variabeln `Petal.Width` är större än 2. Spara denna variabel som `small` på följande sätt.
3. Använd `table()` för att se vilka arter (variabeln `Species`) som är `small`.

2.2 * Extraproblem

1. Skapa en funktion som beräknar värdet på en hypergeometrisk fördelning.
2. Skapa en funktion som beräknar värdet på en Geometrisk fördelning.
3. Pokerhänder: Räkna ut sannolikheten för ett par, triss och "Royal flush" i en pokerhand på 5 kort. Se här för mer info.
4. I vissa fall vill vi simulera data från en given sannolikhetsmodell. Det kan exempelvis vara en linjär modell som ser ut på följande sätt:

$$y_i = \alpha + \beta x_i + \epsilon_i$$

där $\epsilon_i \sim \mathcal{N}(0, \sigma)$. Detta görs enklast i flera steg. I detta fall simulerar jag även x_i samt sätter $\alpha = 2, \beta = 4, \sigma = 1$ och $n = 100$.

```
alpha <- 2
beta <- 4
sigma <- 1
n <- 100

x <- rnorm(n)
y <- alpha + beta*x + rnorm(n, sd=sigma)
```

5. Kör koden ovan och visualisera det simulerade datamaterialet i ett spridningsdiagram [Tips! `ggplot()`]
6. Pröva lite olika värden för σ, β och α och visualisera de olika datamaterialen.
7. Nu ska vi utöka modellen oven till: $y_i = \alpha + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i$ Kör koden nedan. Testa nu att ändra σ, β_1, β_2 och α . Testa att ändra värdet på σ på ett sådant sätt att den kvadratiska sambandet blir väl synligt och blir svårt att se.

```
alpha <- 2
beta <- c(2, 4)
sigma <- 1
n <- 100

x <- rnorm(n)
y <- alpha + beta[1]*x+beta[2]*x^2 + rnorm(n, sd=sigma)
```

Kapitel 3

Housing data

1. Ni ska nu analysera datamaterialet HUS, som innehåller information om en mängd hus. Följande variabler finns i data:
 - Försäljningspris (dollar)
 - Bostadsyta (kvadratfot)
 - Antal sovrum
 - Antal badrum
 - Förekomst av luftkonditionering, 1 = luftkonditionering finns, 0 annars
 - Antal bilar som garaget är konstruerat för
 - Förekomst av pool, 1 = pool finns, 0 annars
 - Byggår
 - Tomtstorlek (kvadratfot)
2. Läs in datamaterialet "HUS.csv" och spara det som **HUS**. Det finns även ett dataset "HUS_eng.csv", som har engelska namn på variablene men innehåller samma data. Materialet finns att tillgå [[här](#)].
3. Gör följande med **HUS**. Använd ggplot2 för att skapa figurerna.
 - (a) Plotta en boxplot över variabeln **Försäljningspris**. Ta fram beskrivande statistik med `summary()` för **Försäljningspris**. Det verkar finnas en del outliers (extremt stora värden), dessa vill vi ta bort från data, kör följande kod:

```
# ta bort alla hus som har pris större än 3:e kvartilen:  
index<-HUS[,1]<quantile(HUS[,1])[4]  
HUS<-HUS[index,]
```
 - (b) Plotta ett histogram för **Försäljningspris**, (bonusfråga: ser fördelningen symmetrisk ut?)
 - (c) Gör en scatter plot mellan **Försäljningspris** och **Bostadsyta**.
 - i. Låt färgen på punkterna bero på värdet på **Antal.sovrum**
 - ii. Låt färgen på punkterna bero på värdet på **Luftkonditionering**
 - iii. Använd `facet_grid()` för att skapa subplots som beror på värdet på **Luftkonditionering**.
 - (d) Beräkna ett tvåsidigt konfidensintervall (KI) med $\alpha = 0.05$ för **Försäljningspris** (tips `?t.test()` spara i `testPris`).
 - (e) Välj ut KI från `testPris`. tips: `?t.test()` och läs under rubriken "Value". Kör sedan `str(testPris)`. Testa `class(testPris)`
 - (f) Beräkna ett tvåsidigt KI med $\alpha = 0.10$ för **Försäljningspris**
 - (g) Beräkna ett enkelsidigt (undre) KI med $\alpha = 0.01$ för **Försäljningspris**

- (h) Kör koden nedan, vad blir resultatet? Hur ska medelvärdet för variabeln `Luftkonditionering` tolkas?

```
summary(HUS)
```

4. Skapa följande frekvenstabeller från HUS (tips: `?table()`)
 - (a) För `Antal.sovrum`
 - (b) För `Luftkonditionering`
 - (c) Mellan variablerna `Antal.sovrum` och `Luftkonditionering`, spara som `sovLuftTab`. Testa `class(sovLuftTab)`
 - (d) Mellan variablerna `Antal.sovrum` och `Antal.badrum`
5. Kör `prop.table(sovLuftTab)` och `prop.table(sovLuftTab, margin=1)`. Vad händer med tabellen?
6. Beräkna fishers exakta test för tabellen `sovLuftTab`, använd $\alpha = 0.05$, vad är noll-hypotesen? Kan vi förkasta den? (tips: `?fisher.test()`)
7. Antag att variablen `Försäljningspris` representerar en hel population med hus. Dra ett slumptässigt stickprov med 20 hus utan återläggning. Beräkna ett tvåsidigt KI ($\alpha = 0.01$) utifrån stickprovet för populationsmedelvärdet.
8. Antag nu att hela datasettet HUS är alla hus i en population. Dra ett stickprov slumptässigt (dvs välj rader) på 40 hus utan återläggning. Gör följande beräkningar utifrån stickprovet:
 - (a) Numeriska variabler: Beräkna ett tvåsidigt KI med $\alpha = 0.01$ för populationsmedelvärdet.
 - (b) Binära(0/1) variabler: Beräkna ett tvåsidigt KI med $\alpha = 0.01$ för populationsandelen. Tips: `?prop.test()`, `?table()`

Kapitel 4

Frivillig fördjupning: Introduktion till linjär regression

Denna laboration kommer inte gå in i teorin bakom (multipel) linjär regression utan kommer fokusera hur man anpassar regressionmodeller, analyserar resultatet och gör diagnostiska tester i R.

4.1 Anpassa en regressionsmodell

Den vanliga regressionmodellen bygger på modellen

$$y_i = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \epsilon_i \quad (4.1)$$

eller med matrisnotation

$$\mathbf{y} = \mathbf{Bx} + \boldsymbol{\epsilon}$$

där $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2)$ där de okända parametrarna är β samt σ i modellen och baserat på våra data vill vi uppskatta dessa parametrar.

I R (och till skillnad mot de flesta statistikprogram) skiljer vi på att anpassa (eller skatta) en modell och studera resultatet från modellen eller använda den för ex. prediktion. För att anpassa en modell använder vi funktionen `lm()`. Det gör att vi kan anpassa en linjär modell och sedan spara den som ett vanligt R-objekt. Sedan kan vi studera detta objekt på ett stort antal sätt, skriva egna funktioner för specifik analys, eller för att grafiskt visualisera modellen.

1. Vi börjar med att läsa in datasetet `Prestige` som finns i paketet `car`. Vi behöver också paketet `MASS`. Installera dessa paket om du inte har dem installerade.

```
library(car)

Loading required package: carData

data(Prestige)
library(MASS)
```

2. Läs på kort om de variabler som finns i datasetet med `?Prestige`.
3. Börja med att visualisera sambandet mellan `prestige` och `income`. [Tips! `plot()`]
4. Vi ska nu anpassa vår första linjära regressionsmodell. För att anpassa en modell i R behöver vi ange två saker, dels en `formula` som beskriver hur modellen ser ut, och sedan vilket dataset som innehåller variablerna vi vill ha i vår modell. För att anpassa en linjär regression med inkomst som oberoende variabel gör vi på följande sätt:

```

minModell <- lm(prestige ~ income, data=Prestige)
minModell

Call:
lm(formula = prestige ~ income, data = Prestige)

Coefficients:
(Intercept)      income
27.1412          0.0029

```

5. Om vi tittar på det resulterande objektet ser vi regressionskoefficienternas värden. Detta är bra för en snabb koll, men senare kommer vi gå in mer på hur vi kan få ut mer utförliga resultat.
6. `prestige ~ income` är ett objekt av klass `formula`. `formula`-objekt används i många funktioner i R för att specificera statistiska modeller på ett flexibelt sätt. Testa att köra `class(prestige ~ income)` och `str(prestige ~ income)`. Likt andra objekt kan `formula`-objekt sparas och manipuleras. Kör koden nedan.

```

x<-prestige ~ income
minModell <- lm(x, data=Prestige)
minModell

```

7. Det går också att bara ange vektorer (de behöver inte heller ligga i samma `data.frame`):

```
minModell2 <- lm(Prestige$prestige ~ Prestige$income)
```

8. Vill vi lägga till flera variabler (andel kvinnor, utbildning) gör vi på följande sätt:

```
minModell3 <- lm(prestige ~ income + women + education, data=Prestige)
```

9. Vi kan på detta sätt enkelt lägga till ett stort antal variabler. Som standard så inkluderas alltid en intercept (β_0 i 4.1) i modellen, vill vi ta bort denna använder lägger vi till `-1`:

```
minModell4 <- lm(prestige ~ income + women - 1, data=Prestige)
```

10. Nu kommer också fördelarna med att ha definierat faktorvariabler. Lägger vi in en faktorvariabel förstår R detta automatiskt och “under the hood” skapas dummyvariabler för vilka koefficienter skattas. Dummyvariabler kommer att förklaras närmare i senare kurser om regression.

```
minModell5 <- lm(prestige ~ income + type, data=Prestige)
```

11. Till sist kan det vara så att vi vill lägga till interaktionseffekter i modellen. Detta görs enkelt med : på följande sätt (detta inkluderar både additiva och multiplikativa effekter):

```
minModell6 <- lm(prestige ~ income:women, data=Prestige)
```

4.2 Analysera resultatet från en linjär regression

Nu har vi anpassat (och smygat på) lite olika modeller baserat på datasetet `Prestige`. Vi ska nu studera de resultat vi fått lite mer. Nu har vi stor nytta av R:s objektorienterade uppbyggnad och generiska funktioner.

1. Vi börjar med att använda funktionen `summary()`. Se exemplet nedan:

```
summary(minModell)

Call:
lm(formula = prestige ~ income, data = Prestige)

Residuals:
    Min      1Q  Median      3Q     Max 
-33.01   -8.38   -2.38    8.43   32.08 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 2.71e+01  2.27e+00   12.0   <2e-16 ***
income       2.90e-03  2.83e-04   10.2   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.1 on 100 degrees of freedom
Multiple R-squared:  0.511, Adjusted R-squared:  0.506 
F-statistic: 105 on 1 and 100 DF,  p-value: <2e-16
```

2. Med denna får vi en sammanfattning av de flesta resultat i modellanpassningen. Pröva denna funktion på `minModell3`. Hitta följande storheter i sammanfattningen av modellen: β , σ , R^2 , F -statistikan samt p-värdena för de olika β -koefficienterna.
3. Pröva att analysera modell 5 och 6 på samma sätt. Hur ser en kategorisk variabel samt interaktionseffekter ut i R?
4. Funktionen `summary()` ger en bra bild av resultatet, men vi vill ofta också studera en ANOVA-tabell för vår modells ingående variabler. För detta används funktionen `anova()`. Pröva den på modellerna 3, 5 och 6.
5. De flesta (icke-bayesianska) statistiker och forskare är mycket förtjusta i p-värden. För att få ut p-värden till ANOVA-tabellen använder vi oss av argumentet `test='Chisq'`. Pröva att på detta sätt testa för variabler i modell 5.
6. Vi kan också inkludera flera modeller i en ANOVA-tabell. Vad ger det för resultat?

```
anova(minModell, minModell3, test="Chisq")
```

4.2.1 Använda parametrar och resultat för vidare analys

Vill vi använda vissa speciella delar av en modell kan vi plocka ut delar från modellen med olika funktioner. Exempelvis kanske vi är intresserad av att använda β -koefficienterna i modellen till något annat. Eller använda modellen för att göra prediktioner på nya data.

1. Pröva att använda funktionen `coef()` på modellobjekt 3 ovan. Pröva att spara ned resultatet som ett nytt objekt. Vad får du för resultat? Jämför med `print()`.

2. På ett liknande sätt kan vi snabbt få ut alla residualer (om vi vill studera dessa) med funktionen `resid()`. Pröva denna funktion på modell 3 ovan och plotta residualerna i ett histogram. Är residualerna normalfördelade? [Tips! `hist(),geom_histogram()`]
3. Pröva att med hjälp av residualvektorn och relationsoperatorer ta fram vilket yrke har den största negativa residualen (d.v.s. lägst prestige kontrollerat för utbildning, inkomst och könsfördelning). [Tips! `which.min()`]
4. Vi kan också få ut de predicerade värdena för varje observation med `predict()`. Pröva att på detta sätt se vilket yrke som har den högsta respektive lägsta förväntade prestigen. [Tips! `which.max()`]
5. Vi kan också använda `predict()` för att skapa prediktioner på nya data. Då behöver vi ta ett nytt dataset (men med samma variabelnamn och variabeltyper) och ange detta data med argumentet `newdata`. Pröva att ta de fem första raderna i datasetet `Prestige` och spara det som `newPrestige`. Pröva att predciera variabeln `prestige` för detta dataset med modell 6.

4.3 Tester och diagnostik

I linjär regression görs ett stort antal antagande om i modellen som ligger till grund för att kunna dra slutsatser från materialet. Nedan följer ett antal tester och visualiseringar för att diagnostisera ett antal centrala antaganden i linjär regression.

Observera att syftet med denna del är att testa lite olika funktionalitet i R, för mer fördjupad genomgång av de olika antagandena och hur dessa problem avhjälpes se dokumentationen till funktionerna eller i litteratur på området (en bra sammanfattnings är [här]).

Välj en godtycklig modell ovan (eller skapa en egen ny modell) och utför följande diagnostik:

1. Det första och enklaste sättet att diagnostisera vår modell är att vi använder funktionen `plot()` på vårt modellobjekt. Pröva `plot()` på modell 3, 5 och 6.
2. Nedan finns lite olika diagnostiska verktyg och kodexempel. Pröva på detta sätt att...
 - (a) Identifiera uteliggare

```
outlierTest(minModell)
qqPlot(minModell)
leveragePlots(minModell)
```

- (b) Identifiera observationer med starkt inflytande på modellen

```
avPlot(minModell)
influencePlot(minModell)
```

- (c) Utvärdera linjäritetsantagande för regressionkoefficienterna

```
crPlots(minModell)
ceresPlots(minModell)
```

- (d) Studera multikollinearitet mellan regressionskoefficienterna

```
vif(minModell)
```

- (e) Oberoende feltermer (framförallt för tidsserieregession)

```
durbinWatsonTest(minModell)
```

(f) Residualernas fördelning

```
qqPlot(minModell)
```

(g) Konstant varians (homoscedasticitet)

```
ncvTest(minModell)
spreadLevelPlot(minModell)
```

3. Pröva att baserat på dessa tester att anpassa den modell för variabeln `prestige` som du själv tror mest på. Vad är dina slutsatser?

4.3.1 Anscombes data

Vi ska nu pröva ett klassiskt exempel när det gäller linjär regression, `anscombes` data. Materialet består av fyra x -variabler och fyra y -variabler där materialet ser mycket olika ut, även om de enskilda regressionsmodellerna har exakt samma resultat.

1. Börja med att läsa in materialet i R med `data()`.

```
data(anscombe)
```

2. Anpassa nu följande fyra regressionsmodeller i R utan att plotta materialet.

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 x_1 + \epsilon \\y_2 &= \beta_0 + \beta_1 x_2 + \epsilon \\y_3 &= \beta_0 + \beta_1 x_3 + \epsilon \\y_4 &= \beta_0 + \beta_1 x_4 + \epsilon\end{aligned}$$

3. Studera koefficienterna i modellerna. De ska vara nästan identiska.
4. Pröva nu att plotta datamaterialet och använd de diagnostiska verktygen ovan. Vilka antaganden är problematiska i respektive modell, och vilka diagnostiska verktyg fångar upp detta?

Del II

Inlämningsuppgifter

Inlämning

Utgå från laborationsmallen, som går att ladda ned här, när du gör inlämningsuppgifterna. Spara denna som labb[no]_[liuID].R , t.ex. labb1_josad732.R om det är laboration 1. Ta inte med hakparenteser i filnamnet. Denna fil ska laddas upp på LISAM och ska **inte** innehålla något annat än de aktuella funktionerna, namn- och ID-variabler och ev. kommentarer. Alltså **inga** andra variabler, funktionsanrop för att testa inlämningsuppgifterna eller anrop till markmyassignment-funktioner.

Tips!

Inlämningsuppgifterna innebär att konstruera funktioner. Ofta är det bra att bryta ned programmeringsuppgifterna i färre små steg och testa att det fungerar i varje steg.

1. Lös uppgiften med vanlig kod direkt i R-Studio (precis som i datorlaborationen ovan) utan att skapa en funktion.
2. Testa att du får samma resultat som testexemplen.
3. Implementera koden du skrivit i 1. ovan som en funktion.
4. Testa att du får samma resultat som i testexemplen, nu med funktionen.

Automatisk återkoppling med **markmyassignment**

Som ett komplement för att snabbt kunna få återkoppling på de olika arbetsuppgifterna finns paketet **markmyassignment**. Med detta är det möjligt att direkt få återkoppling på uppgifterna i laborationen, oavsett dator. Dock krävs internetanslutning.

Information om hur du installerar och använder **markmyassignment** för att få direkt återkoppling på dina laborationer finns att tillgå [här](#).

Samma information finns också i R och går att läsa genom att först installera **markmyassignment**.

```
install.packages("markmyassignment")
```

Om du ska installera ett paket i PC-pularna så behöver du ange följande:

```
install.packages("markmyassignment", lib="sökväg till en mapp i din hemkatalog")
```

Tänk på att i sökvägar till mappar/filer i R i Windowssystem så används "\\\", tex "C:\\\\Users\\\\Josef".

Därefter går det att läsa information om hur du använder **markmyassignment** med följande kommando i R:

```
vignette("markmyassignment")
```

Det går även att komma åt vignetten [här](#). Till sist går det att komma åt hjälpparserna och dokumentationen i **markmyassignment** på följande sätt:

```
help(package="markmyassignment")
```

Lycka till!

Kapitel 5

Inlämningsuppgifter

För att använda `markmyassignment` i denna laboration ange:

```
library(markmyassignment)

Loading required package: methods
Loading required package: yaml
Loading required package: testthat
Loading required package: httr
Loading required package: checkmate

lab_path <-
"https://raw.githubusercontent.com/STIMALiU/KursRprgm/master/Labs/Tests/d7.yml"
suppressWarnings(set_assignment(lab_path))

Assignment set:
D7: Statistisk programmering med R: Lab 7
The assignment contain the following (2) tasks:
- diagonalize_matrix
- my_grouped_test
```

5.1 `my_grouped_test()`

Nu ska ni skapa en funktion som ska beräkna gruppvisa konfindesintervall (KI) för en variabel. Innan ni börjar se till att HUS-data är inläst och kör kodden nedan för att ta bort de extremt stora värdena:

```
# Download
file_path <-
"https://raw.githubusercontent.com/STIMALiU/KursRprgm/master/Labs/DataFiles/HUS.csv"
HUS <- remis::source_data(file_path)

Downloading data from: https://raw.githubusercontent.com/STIMALiU/KursRprgm/master/Labs/DataFiles/HU

SHA-1 hash of the downloaded data file is:
777f771c0493bca3910d619136aed9f4265a2a1d

# Small corrections (removing outliers)
index<-HUS[,1] < quantile(HUS[,1]) [4]
HUS<-HUS[index,]
```

Funktion ska heta `my_grouped_test()` och ha argumenten:

- `data_vector` - är en numerisk vektor
- `my_groups` - är en factor/character-vektor som grupperar `data_vector`

- **alpha** - är signifikansnivån för intervallet, **alpha=0.05** ska ge ett 95 % konfidensintervall.

Funktionen ska returnera en matris **result** där raderna motsvarar grupperna i **my_groups** och har fyra kolumner: Undre gräns för KI, medelvärdet, övre gräns för KI och antal observationer i varje grupp. Se testfallen för namnen på kolumnerna. Raderna ska ha samma namn som grupperna **my_groups**.

Förslag till lösning:

1. Se till att **my_groups** är en faktor. Räkna ut hur många grupper som finns i **my_groups**. **Tips!** `?levels()` `?table()`
2. Skapa en tom matris av rätt storlek, kalla den **result**. Ge den lämpliga namn. **Tips!** `?colnames()`, `?rownames()`
3. Spara antalet observationer för varje grupp i den fjärde variabeln i **result**.
4. Använd **by()** kombinerat med **t.test()** för att beräkna gruppvisa KI, spara i **group_test**. Testa `?by()`, ni ser att det finns ett argument som heter “...” för funktionen **by()**. Dessa tre punkter kan ersättas med argument som behövs till funtionsen “FUN”. Mer tips: `str("objekt från t.test")` och `?by` läs under rubriken “value” för att kolla vad **by()** returnerar.
5. Loopa över antalet grupper och välj ut KI och medelvärde för varje grupp från **group_test**. Spara på rätt ställen i **result**.
6. Returnera **result**.

Testa om testfallen nedan fungerar:

```
my_grouped_test(HUS[,1],HUS$Luftkonditionering,0.01)
```

	Lower CI-limit	Mean	Upper CI-limit	No of obs.
0	161468	173473	185479	82
1	213182	220556	227930	308

```
my_grouped_test(HUS[,2],HUS$Pool,0.10)
```

	Lower CI-limit	Mean	Upper CI-limit	No of obs.
0	1918.7	1955.5	1992.3	372
1	1890.6	2041.5	2192.4	18

```
# Chickwts-data
```

```
data(chickwts)
```

```
my_grouped_test(chickwts[,1],chickwts[,2],0.05)
```

	Lower CI-limit	Mean	Upper CI-limit	No of obs.
casein	282.64	323.58	364.52	12
horsebean	132.57	160.20	187.83	10
linseed	185.56	218.75	251.94	12
meatmeal	233.31	276.91	320.51	11
soybean	215.18	246.43	277.68	14
sunflower	297.89	328.92	359.95	12

5.2 Miniprojektet del II

Den sista delen av denna laboration är att genomföra miniprojektet del II. Se kurshemssidan för detaljer.
Nu är du klar!

Litteraturförteckning

- [1] Hadley Wickham. A layered grammar of graphics. *Journal of Computational and Graphical Statistics*, 19(1):3–28, 2010.
- [2] Leland Wilkinson. *The grammar of graphics*. Springer, 2012.
- [3] Leland Wilkinson, D Wills, D Rope, A Norton, and R Dubbs. *The grammar of graphics*. Springer, 2006.